

Online Shoppers Purchasing Intention Dataset

Projekat iz predmeta Mašinsko učenje

Uvod

- Online Shoppers Purchasing Intention Dataset
- Cilj rada
- Logistička regresija
- Random Forest
- Potpuno povezane neuronske mreže


Skup podataka



- Online Shoppers Purchasing Intention Dataset
- 12 330 sesija opisanih pomoću 18 atributa

Administrative	Administrative_Duration	Informational	Informational_Duration	ProductRelated	ProductRelated_Duration	BounceRates	ExitRates	PageValues	SpecialDay	Month	OperatingSystems	Browser	Region	TrafficType	VisitorType	Weekend	Revenue
0	0	0	0	0	1	0	0.2	0.2	0	0 Feb	1	1	1	1	Returning_Visitor	FALSE	FALSE
0	0	0	0	0	2	64	0	0.1	0	0 Feb	2	2	1	2	Returning_Visitor	FALSE	FALSE
0	0	0	0	0	1	0	0.2	0.2	0	0 Feb	4	1	9	3	Returning_Visitor	FALSE	FALSE
0	0	0	0	0	2	2.666666667	0.05	0.14	0	0 Feb	3	2	2	4	Returning_Visitor	FALSE	FALSE

Priprema podataka i analiza

- Provera nedostajućih vrednosti i duplikata
- Transformacija binarnih promenljivih u 0/1
- Enkodiranje one-hot metodom
- Izražena desna asimetrija
- Korelacija sa ciljnom promenljivom
- PageValues ima najjaču vezu







- Iako mesec maj ima najviše sesija, novembar ima najvišu stopu kupovina – verovatno usled Black Friday akcija

Modeli – Logistička regresija

- Model1:
 - Najbolji C parametar: 100
 - ROC-AUC 0,904 na validacionom i 0,466 na test skupu
 - Accuracy 0,470
 - Precision 0,138
 - Recall 0,465
 - F1 score 0,213






- Model2 SMOTE:
 - Najbolji sampling_strategy 1 i najbolji C 10
 - ROC-AUC 0,903 na validacionom i 0,901 na test skupu
 - Accuracy 0,857
 - Precision 0,527
 - Recall 0,738
 - F1 score 0,615






Modeli – Random Forest

- Najbolje vrednosti parametara n_estimators 200 i max_depth None
 - ROC-AUC 0,919 na validacionom i 0,921 na test skupu
 - Accuracy 0,896
 - Precision 0,738
 - Recall 0,509
 - F1 score 0,603



Modeli – Neuronske mreže


- Tri arhitekture različite dubine
 - Jednostavna arhitektura sa 1 skrivenim slojem
 - Arhitektura sa 2 skrivena sloja
 - Složena arhitektura sa tri skrivena sloja i Dropout regularizacijom



- Modeli 1 i 3 postižu skoro identičan ROC-AUC na validacionom skupu, model 2 pokazuje izražen overfitting – validacioni AUC opada nakon epohe 15

Poređenje modela neuronske mreže

- Model 1
 - ROC-AUC 0,909 na test skupu
 - Accuracy 0,893
 - Precision 0,705
 - Recall 0,530
 - F1 score 0,605
- Model 2
 - ROC-AUC 0,890 na test skupu
 - Accuracy 0,883
 - Precision 0,647
 - Recall 0,546
 - F1 score 0,592
- Model 3
 - ROC-AUC 0,908 na test skupu
 - Accuracy 0,889
 - Precision 0,685
 - Recall 0,524
 - F1 score 0,593



Zaključak

- Poređenje sva tri pristupa na test skupu:
 - Logistička regresija SMOTE: ROC-AUC 0,901 F1 0,615
 - Random Forest: ROC-AUC 0,924 F1 0,603
 - Neuronska mreža Model 1: ROC-AUC 0,909 F1 0,605
- Izabran model: Random Forest
 - Najviši ROC-AUC i najbolji balans preciznosti i odziva
 - Ne zahteva standardizaciju
 - Feature importance se poklapa sa korelacionom analizom sa početka
 - Manje sklon preprilagođavanju u odnosu na neuronske mreže

Hvala na pažnji